

《中期进展报告：高血糖风险预警与可解释性分析》

一、数据处理细节

1. 技术细节和操作逻辑：

(1) 数据来源：皮马印第安人糖尿病数据库（NIDDK）。

(2) 清洗逻辑：

识别报警：发现存在血糖、血糖等指标大量“0”值，判定为数据，采用中补充补充。

异常值抑制：采用四分位距（IQR）法对 BMI 和胰岛素水平进行了平滑处理，增强模型稳定性。

标准化：实行了 StandardScaler 标准化，确保不同量级的生理指标（如血糖 140 vs BMI 30）在模型中具有同等权重。

2. 数据清洗代码

<https://github.com/qieqiesha/hyperglycemia-risk-alert/blob/d1c8a62877b96508bc4533ecf72bd8137c4d7ff1/%E6%95%B0%E6%8D%AE%E5%A4%84%E7%90%86.py>

3. 清洗后数据档案

https://github.com/qieqiesha/hyperglycemia-risk-alert/blob/d1c8a62877b96508bc4533ecf72bd8137c4d7ff1/diabetes_cleaned.csv

二、模型设计思路

本项目为高血糖风险二分类预警任务，采用 Scikit-learn 构建机器学习模型。

首先将数据集按 8:2 分层抽样划分为训练集与测试集，对数值特征（Glucose、BMI、Insulin 等）进行标准化处理。

选用逻辑回归作为基线模型，随机森林作为主模型，XGBoost 作为对比模型。

模型评估以 AUC、Recall 为核心指标，重点保证高风险人群检出率。

模型训练完成后接入 SHAP 框架，实现全局特征重要性与个体风险归因的可解释性分析，满足临床辅助决策需求。

三、可视化成果

1. 关键特征分布对比直方图

<https://github.com/qieqiesha/hyperglycemia-risk-alert/blob/d1c8a62877b96508bc4533ecf72bd8137c4d7ff1/%E5%85%B3%E9%94%AE%E7%89%B9%E5%BE%81%E5%88%86%E5%B8%83%E5%AF%B9%E6%AF%94%E7%9B%B4%E6%96%B9%E5%9B%BE.png>

2. 正负样本特征分布箱线图

<https://github.com/qieqiesha/hyperglycemia-risk-alert/blob/d1c8a62877b96508bc4533ecf72bd8137c4d7ff1/%E6%AD%A3%E8%B4%9F%E6%A0%B7%E6%9C%AC%E7%89%B9%E5%BE%81%E5%88%86%E5%B8%83%E7%AE%B1%E7%BA%BF%E5%9B%BE.png>

3. 特征与标签相关性排序

<https://github.com/qieqiesha/hyperglycemia-risk-alert/blob/d1c8a62877b96508bc4533ecf72bd8137c4d7ff1/%E7%89%B9%E5%BE%81%E4%B8%8E%E6%A0%87%E7%AD%BE%E7%9B%B8%E5%85%B3%E6%80%A7%E6%8E%92%E5%BA%8F.png>

4. 特征间相关性热力图

<https://github.com/qieqiesha/hyperglycemia-risk-alert/blob/d1c8a62877b96508bc4533ecf72bd8137c4d7ff1/%E7%89%B9%E5%BE%81%E9%97%B4%E7%9B%B8%E5%85%B3%E6%80%A7%E7%83%AD%E5%8A%9B%E5%9B%BE.png>

四、问题及解决方案

1. 逻辑缺失值的识别与处理

问题：在初步探索数据集时，发现血糖（Glucose）、血糖（BloodPressure）、BMI 等关键生

理指标存在大量“0”值。从医学角度分析，活人的这些指标不可能为 0，因此判定这些“0”并非数值真实，而是数据采集过程中的隐性行为。

解决方案：

首先，使用 `replace(0, np.nan)` 将逻辑错误的 0 值转换为标准输出值格式。

考虑到生理指标受过度健康状况影响增大，不采用简单的补充法，而是选择了更加鲁棒性的中位数（Median）补充法，以保证数据的生物学合理性。

2. 极端异常值的干扰

问题：集中数据部分特征（如胰岛素、胰岛素和 BMI）存在极普遍远超常人的数值。这些异常点（Outliers）在模型训练中会加大产生增量偏移，导致模型泛化能力下降。

解决方案：

引入了统计学中的 IQR（四分位距）检测法。

定义了数据的合理区间 $[Q1 - 1.5IQR, Q3 + 1.5IQR]$ ，并编写了 `clip_outliers` 函数，对超出边界的异常值进行平滑截断处理，既保留了样本，又绘制了噪声。

3. 特征量纲不统一问题

问题：不同特征的数值范围差异巨大。例如，高血压值通常在 100 左右，而糖尿病遗传函数（Pedigree）则在 0.5 左右。直接输入模型会导致权重分配不均，大数值特征会忽略小数值特征的影响。

解决方案：

根据 A08 任务书要求，对所有特征执行了 Z-score 标准化（StandardScaler）。

将所有数据缩放至均值为 0、角度为 1 的分布中，保证了各生理指标在模型评价体系中的公平性。

4. 团队中协作的环境配置与数据同步

问题：初始方案采用读取本地 `diabetes.csv` 的方式。在小组协作中，不同成员的电脑文件路径不一（如 `D:\backup\` 与 `C:\Users\`），并且手动复制文件很容易导致数据版本不一致。

解决方案：

重构代码逻辑：废弃用本地读取，改用 URL 动态调用云端数据集。

通过硬编码 GitHub 镜像链接和特征名称映射，实现了代码的“一键即运行”，解决了路径配置烦恼，确保全组成员在模型开发阶段使用完全同一套清洗后的标准数据。