

《选题报告：高血糖风险预警与可解释性分析》

一、项目简介

本项目以高血糖（糖尿病前期/糖尿病）为核心慢病对象，围绕临床需求构建兼具精度与可解释性的风险预警模型，实现高血糖风险预警。

项目基于公开健康数据集，整合年龄、BMI、血糖、血脂、家族史等多维度特征，完成数据整理与指标对齐，形成标准化建模样本；采用数据预处理流程，开展异常值核查、标准化与特征相关性分析，提升数据质量，为模型训练提供可靠支撑；使用 Scikit-learn 构建分类模型，结合 SHAP 可解释算法，量化指标贡献度，实现高血糖风险精准预测与个体归因解释；输出患者级风险解释案例，系统分析误判原因与使用注意事项，提升模型可信度，满足临床辅助决策需求。

二、数据来源

1. 数据集名称：

Diabetes Health Indicators Dataset (BRFSS 2015)

2. 数据官方来源：

该数据源自美国疾病控制与预防中心（CDC）开展的“行为风险因素监测系统”（Behavioral Risk Factor Surveillance System, BRFSS）2015 年年度调查数据。原始数据集通过大规模电话问卷调查获得，涵盖了全美居民的健康指标及生活习惯。

本项目通过全球领先的开源数据科学平台 Kaggle 获取经脱敏处理后的结构化数据集（CSV 格式），确保了数据的公开性与获取的合法性。

三、参考代码链接：

[Diabetes Health Indicators EDA, Modeling & SHAP](#)

Kaggle 官方高分 Notebook。这是该数据集在 Kaggle 上的核心代码库，包含了完整的数据清洗、特征工程和多种模型对比。

[Diabetes-Risk-Prediction-Project \(AAdewunmi\)](#)

包含端到端的机器学习流水线，集成了 SHAP 和 LIME 解释工具，甚至带有一个 Flask Web 展示界面，符合“临床预警”和“归因分析”的需求。

[Diabetes-Risk-Prediction-with-XAI](#)

该项目专门针对糖尿病预测模型进行了 SHAP 和 LIME 的深度集成，重点查看 SHAP 解释部分的实现以及如何将模型预测结果转化为临床可读的解释。

四、团队分工 (Team Division)

1. 李名扬：数据采集与预处理负责人

基于公开高血糖数据集完成数据加载、异常值核查、缺失值处理与标准化，构建可用建模数据集，为模型训练提供高质量数据支撑。

2. 陈建达：数据分析与可视化负责人

利用 Pandas、Matplotlib 完成特征统计、相关性分析与可视化输出，挖掘关键风险因素，为模型选择与特征工程提供依据。

3. 石铮铮：模型构建与训练负责人

使用 Scikit-learn 搭建并训练高血糖风险分类模型，完成模型对比、调参与评估指标计算，实现稳定可靠的风险预测。

4. 邵梓懿：可解释性分析与报告撰写负责人

使用 SHAP/LIME 完成个体风险归因与案例解读，分析误判原因与应用边界，撰写技术报告、整理 PPT 与项目总结。